Čtení exekučních plánů

Prague PostgreSQL Developer Day 2016 / 17.2.2015

Tomáš Vondra

tomas.vondra@2ndquadrant.com / tomas@pgaddict.com

Agenda

- úvod a trocha teorie
  - princip plánování, výpočet ceny
- praktické základy
  - EXPLAIN, EXPLAIN ANALYZE, ...
- základní operace, varianty
  - skeny, joiny, agregace, ...
- obvyklé problémy
- ukázky dotazů

Zdroje

PostgreSQL dokumentace

- Row Estimation examples
  http://www.postgresql.org/docs/devel/static/row-estimation-examples.html
- EXPLAIN
  http://www.postgresql.org/docs/current/static/sql-explain.html
- Using EXPLAIN
  http://www.postgresql.org/docs/current/static/using-explain.html

PostgreSQL 9.0 High Performance

- Query optimization (p. 233 - 296)
  - planning basics, EXPLAIN usage
  - processing nodes
  - statistics
  - planning parameter

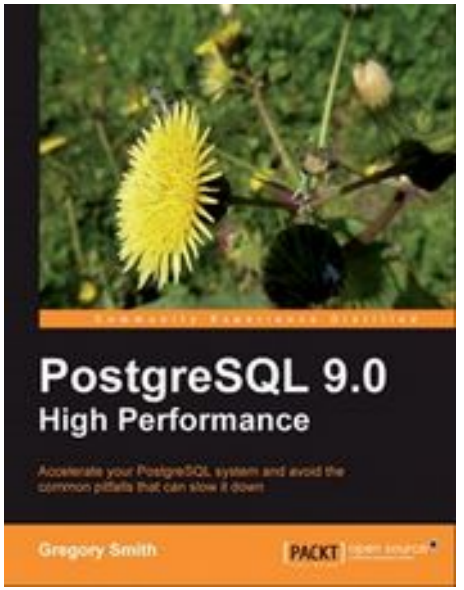

Proč se o plánování starat?

- SQL je deklarativní jazyk
  - popisuje pouze požadovaný výsledek
  - volba postupu jeho získání je úkolem pro databázi

- Porozumění plánování je předpoklad pro
  - pochopení limitů databáze (implementačních, obecných)
  - definici efektivní DB struktury
  - analýzu problémů se stávajícími dotazy (pomalé, OOM)
  - lepší formulaci SQL dotazů

Plánování jako optimalizace

- hledáme “optimální” z ohromného množství plánů
  - Mají se použít indexy? Které?
  - V jakém pořadí a jakým algoritmem se mají provést joiny?
  - Které podmínky se mají vyhodnotit první?
- koncovým kritériem je čas běhu dotazu
  - strašně špatně se odhaduje a modeluje
- namísto toho se pracuje s “cenou”
  - vyjadřuje nároky daného plánu na prostředky (CPU, I/O)
  - čím méně operací musím udělat, tím rychlejší dotaz
  - založeno na statistikách tabulek / indexů a odhadech

Cost proměnné

- udávají cenu některých základních operací
- celková cena se z nich vypočítává
- I/O operace jsou výrazně nákladnější

• **`seq_page_cost = 1.0`**	sekvenční čtení stránky (seq scan)
• **`random_page_cost = 4.0`**	náhodné čtení stránky (index scan)
• **`cpu_tuple_cost = 0.01`**	zpracování řádky z tabulky
• **`cpu_index_tuple_cost = 0.005`**	zpracování řádky indexu
• **`cpu_operator_cost = 0.0025`**	vyhodnocení podmínky (WHERE)

Ukázka výpočtu ceny

- hledáme “optimální” z ohromného množství plánů

```
SELECT * FROM tabulka WHERE sloupec = 100
```

- tabulka má 1.000 stránek a 10.000 řádek

```
cena = 1000 * seq_page_cost +
       10000 * cpu_tuple_cost +
       10000 * cpu_operator_cost
```

Ukázka výpočtu ceny

- hledáme “optimální” z ohromného množství plánů

```
SELECT * FROM tabulka WHERE sloupec = 100
```

- tabulka má 1.000 stránek a 10.000 řádek

```
cena = 1000 * 1.0 +
       10000 * 0.01 +
       10000 * 0.0025 = 1125
```

cvičení: 01-vypocet-ceny.sql

Cena vs. čas

- víceméně virtuální hodnota
  - vyjadřuje nároky daného plánu na prostředky (CPU, I/O)
  - korelace s časem, ale nelineární vztah
- stabilita vzhledem ke vstupním parametrům
  - malá změna v selektivitě podmínek / odhadech – malá změna ceny
- stabilita vzhledem k času
  - malá změna ceny – malá změna času
  - vzhledem k času

Toto činí cost-based plánování odolné vůči (malým) chybám.

Plán jako strom

```
SELECT * FROM t;
```

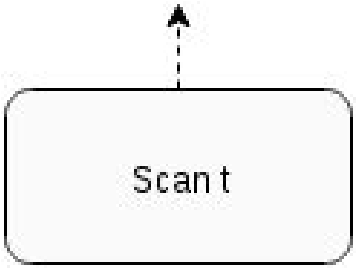

Plán jako strom

```
SELECT * FROM t ORDER BY a LIMT 10;
```

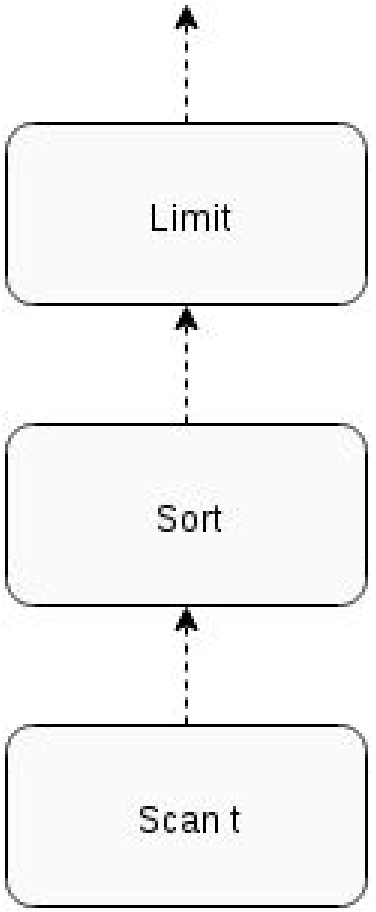

Plán jako strom

```
SELECT * FROM t1 JOIN t2 ON (…) JOIN t3 ON (…)
```

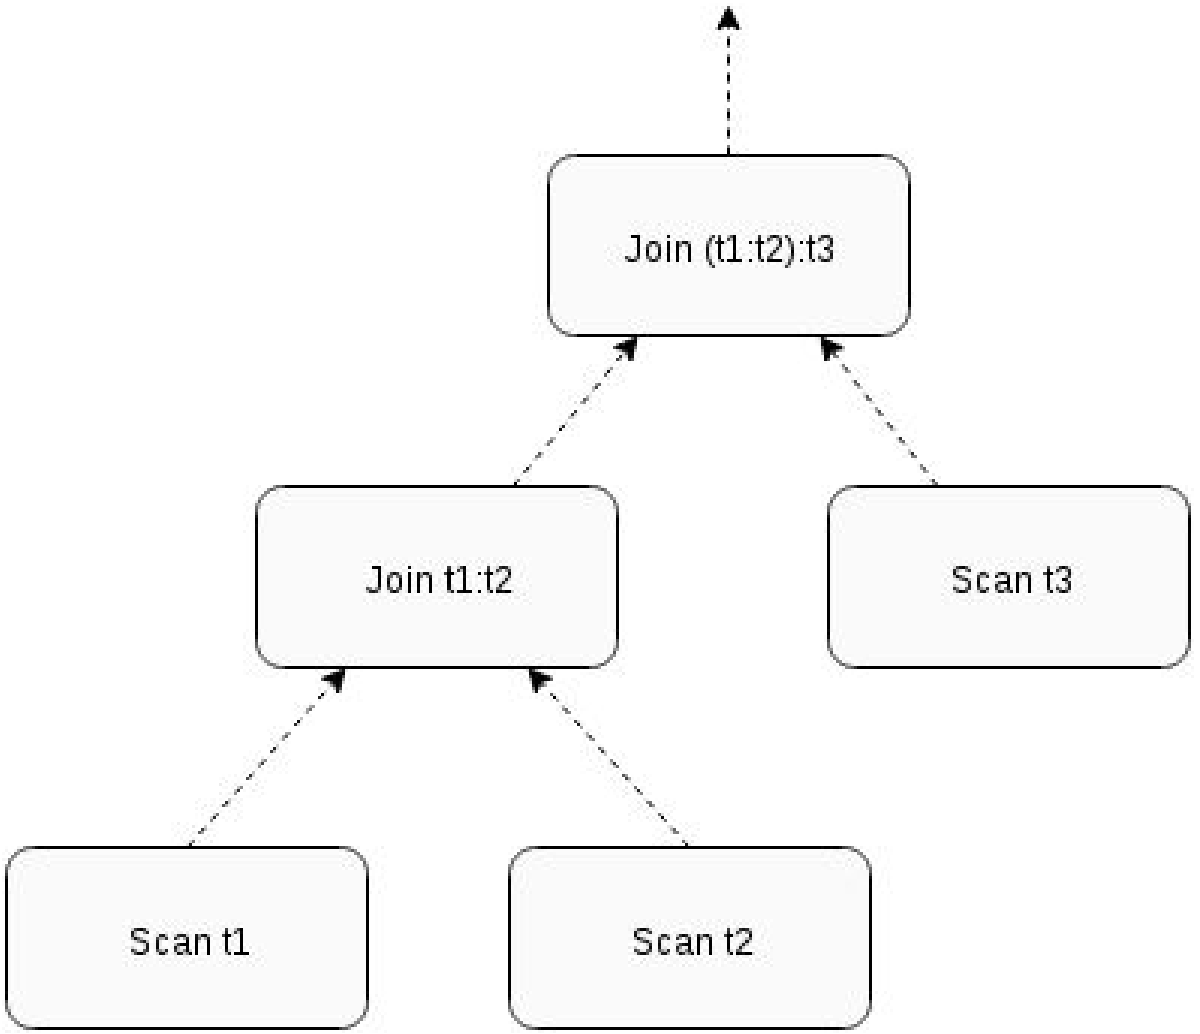

Statistiky

- plánovač potřebuje odhadovat
  - velikosti tabulek (skeny)
  - velikosti mezivýsledků (vstupy vnitřních uzlů)
  - selektivitu podmínek (kvůli mezivýsledkům)
- databáze si udržuje statistiky o datech
  - **`pg_class`** (centrální katalog, obsahuje velikost relací)
  - **`pg_statistic`** (systémový katalog se statistikami sloupců)
  - **`pg_stats`** (pohled na pg_statistic, určeno pro lidi)
- neplést s “runtime” statistikami o provozu (pg_stat_*)

Statistiky

- pg_class – statistiky pro relaci jako celek
  - relpages – počet stránek relace (8kB bloky)
  - reltuples – počet řádek (nedpovídá COUNT(*))

```
CREATE TABLE t2 (id INT);
INSERT INTO t2 SELECT i FROM generate_series(1, 1000000) s(i);
SELECT relpages, reltuples FROM pg_class WHERE relname = 't2';

 relpages | reltuples
----------+-----------
        0 |         0

ANALYZE t2;
SELECT relpages, reltuples FROM pg_class WHERE relname = 't2';
```

Statistiky

- pg_stats (pg_statistic) - statistiky na úrovni sloupců
  - **`avg_width`** – průměrná šířka hodnot (v bytech)
  - **`n_distinct`** – počet různých hodnot ve sloupci (GROUP BY)
  - **`null_frac`** – podíl NULL hodnot ve sloupci
  - **`correlation`** – korelace hodnot s pořadím v tabulce
  - **MCV seznam**
    - most_common_values / most_common_freqs
    - nejčastější hodnoty a jejich frekvence (MCV)
  - **histogram**
    - histogram_bounds
    - equi-depth histogram (přihrádky reprezentují stejné % hodnot)

Statistiky

```
CREATE TABLE t3 (a INT, b INT, c INT, d INT);

INSERT INTO t3
     SELECT
            mod(i,50),   -- 50 hodnot (uniform)
            mod(i,1000), -- 1000 hodnot (uniform)
            1000 * pow(random(),2), -- 1000 hodnot (skewed)
            (CASE WHEN mod(i,3) = 0 THEN NULL ELSE i END)
FROM generate_series(1,1000000) s(i);

ANALYZE t3;

SELECT a, COUNT(*) FROM t3 GROUP BY 1 ORDER BY 1;
SELECT * FROM pg_stats WHERE tablename = 't3' AND attname = $1;
```

cvičení: 02-statistiky.sql

EXPLAIN

- zobrazí exekuční plán dotazu (nespustí ho)
- v plánu jsou uvedeny ceny a odhady počtu řádek

```
EXPLAIN SELECT SUM(a.id) FROM a,b WHERE a.id = b.id;

                              QUERY PLAN
-----------------------------------------------------------------------
 Aggregate  (cost=58.75..58.76 rows=1 width=4)
   ->  Hash Join  (cost=27.50..56.25 rows=1000 width=4)
         Hash Cond: (a.id = b.id)
         ->  Seq Scan on a  (cost=0.00..15.00 rows=1000 width=4)
         ->  Hash  (cost=15.00..15.00 rows=1000 width=4)
               ->  Seq Scan on b  (cost=0.00..15.00 rows=1000 width=4)
```

- plán má stromovou strukturu
- listy jsou tradičně skeny tabulek, výše jsou operace

EXPLAIN

- každý uzel má dvě ceny
  - počáteční (startup) – do vygenerování první řádky
  - celkovou (total) – do vygenerování poslední řádky

```
                                QUERY PLAN
-----------------------------------------------------------------------
 Aggregate  (cost=58.75..58.76 rows=1 width=4)
   ->  Hash Join  (cost=27.50..56.25 rows=1000 width=4)
         Hash Cond: (a.id = b.id)
         ->  Seq Scan on a  (cost=0.00..15.00 rows=1000 width=4)
         ->  Hash  (cost=15.00..15.00 rows=1000 width=4)
               ->  Seq Scan on b  (cost=0.00..15.00 rows=1000 width=4)
```

- např. Hash Join má “startup=27.50” a total=”56.25”
  - očekávaný počet řádek je 1000, průměrná šířka 4B

EXPLAIN ANALYZE

- jako EXPLAIN, ale navíc dotaz provede a vrátí také
  - reálný čas (opět startup/total, jako v případě ceny)
  - skutečný počet řádek, počet opakování

```
EXPLAIN ANALYZE SELECT SUM(a.id) FROM a,b WHERE a.id = b.id;

                                 QUERY PLAN
-------------------------------------------------------------------------
 Aggregate  (cost=58.75..58.76 rows=1 width=4)
            (actual time=4.149..4.149 rows=1 loops=1)
   ->  Hash Join  (cost=27.50..56.25 rows=1000 width=4)
                          (actual time=1.515..3.654 rows=1000 loops=1)
         Hash Cond: (a.id = b.id)
         ->  Seq Scan on a  (cost=0.00..15.00 rows=1000 width=4)
                          (actual time=0.036..0.533 rows=1000 loops=1)
         ->  Hash  (cost=15.00..15.00 rows=1000 width=4)
                   (actual time=1.440..1.440 rows=1000 loops=1)
               Buckets: 1024  Batches: 1  Memory Usage: 36kB
               ->  Seq Scan on b  (cost=0.00..15.00 rows=1000 width=4)
                          (actual time=0.027..0.560 rows=1000 loops=1)
 Total runtime: 4.263 ms
```

explain.depesz.com

- zachovává strukturu z EXPLAIN (ANALYZE)
- vytáhne podstatné informace, zvýrazní problémy (statistiky, doba běhu)
- dobrý sdílení exekučních plánů např. po mailu / chatu
- http://explain.depesz.com/

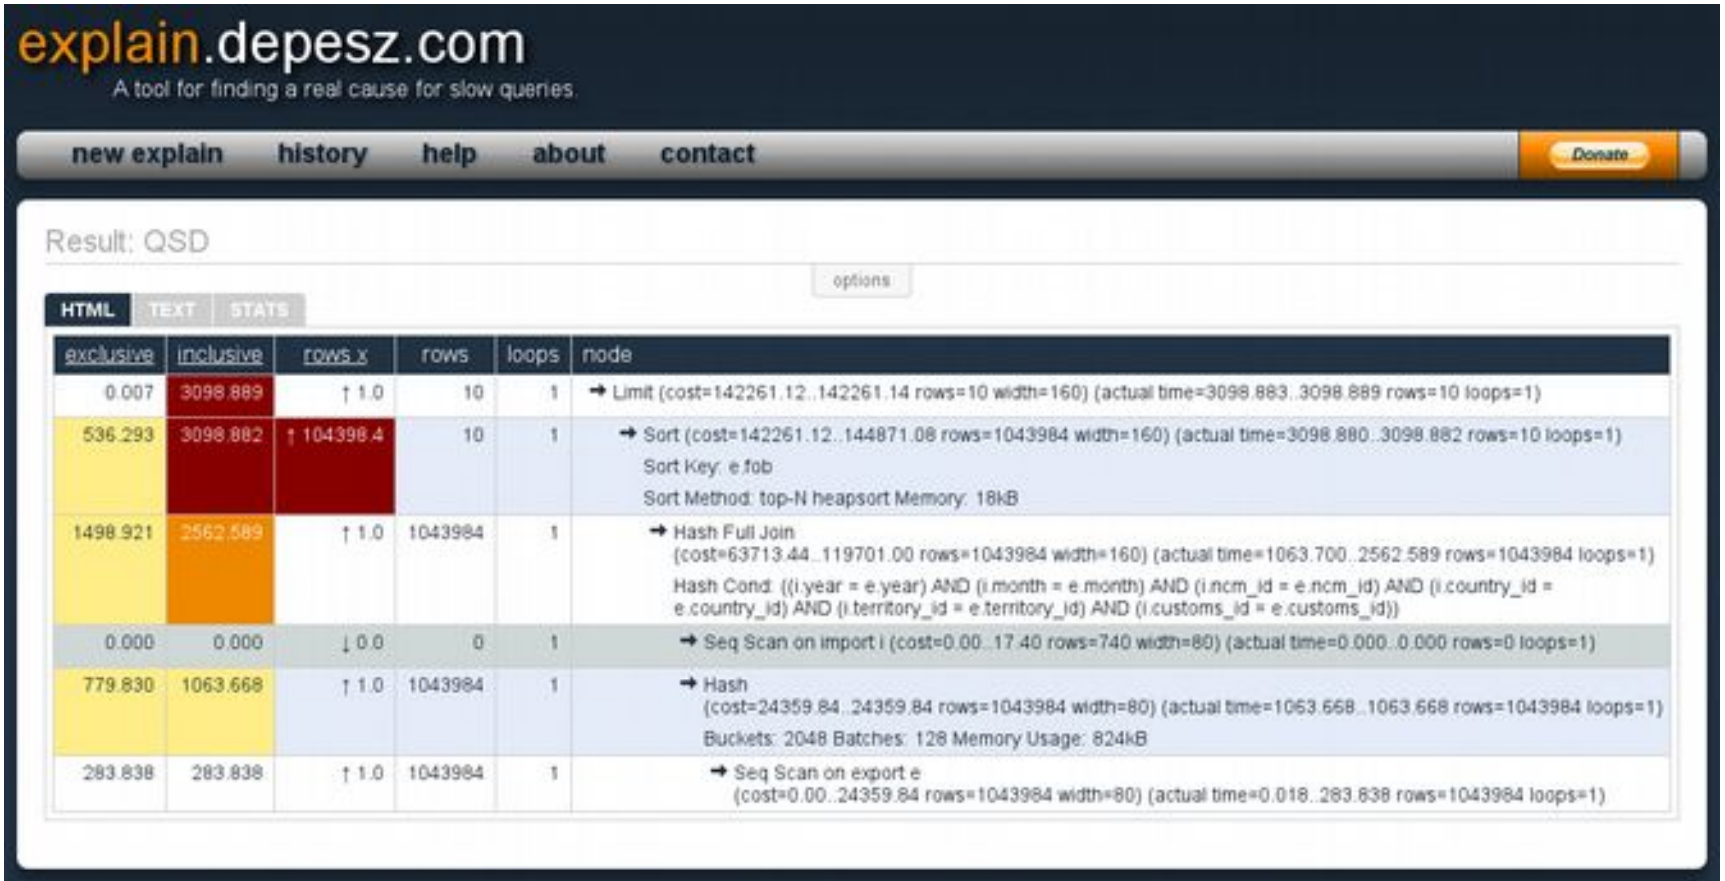

PgAdmin

- pohled založený na “toku” dat mezi operacemi
- stromová struktura, nicméně tok “zleva doprava”
- znázornění počtu řádek pomocí šířky spojnice

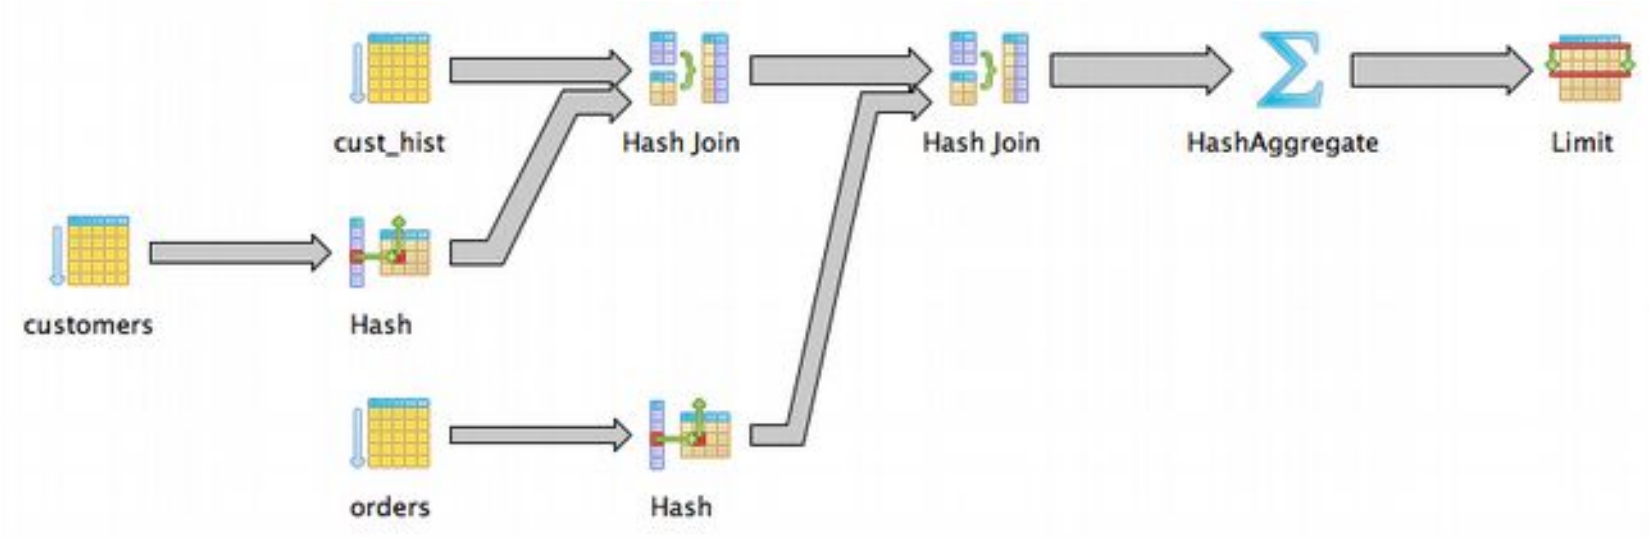

pev (Postgres EXPLAIN Visualizer)

- jasně ukazuje stromovou strukturu
- http://tatiyants.com/pev/

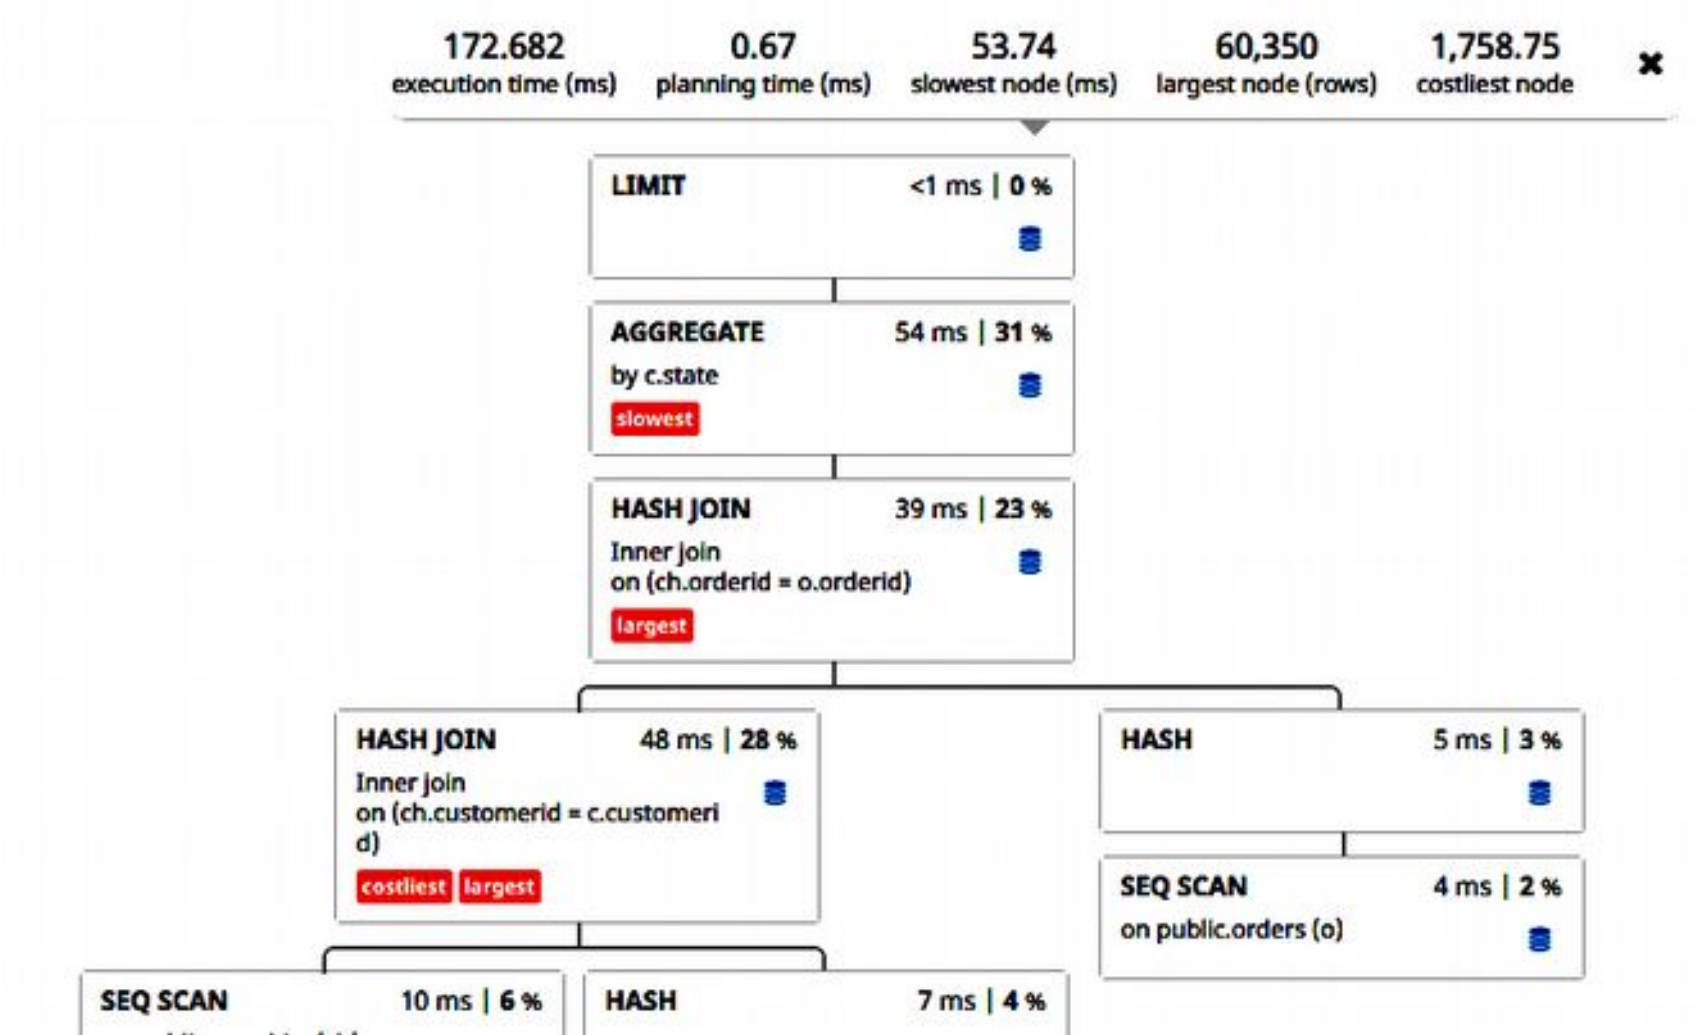

pg_test_timing

- instrumentace v EXPLAIN ANALYZE není zadarmo
- často se stává že měření času má značný overhead
  - dotaz pak běží např. 10x déle a mění se poměr kroků
  - závisí na HW/OS
- možnost otestovat nástrojem v PostgreSQL

```
$ pg_test_timing
    Testing timing overhead for 3 seconds.
    Per loop time including overhead: 23.49 nsec
    Histogram of timing durations:
    < usec:      count   percent
            8:          2  0.00000%
            4:         39  0.00003%
            2:    2999907  2.34869%
            1:  124726830 97.65128%
```

- histogram, cílem je mít >90% pod 1 usec

Obvyklé problémy

Soustřeďte se na operace s ...

- velkou odchylkou odhadu počtu řádek a reality
  - chyby menší než o řád jsou vesměs považovány za malé
  - skutečným problémem jsou odchylky alespoň o řád (10x více/méně)
- největším proporcionálním rozdílem mezi odhadem a reálným časem
  - např. uzly s cenami 100 a 120, ale časy 1s a 1000s
  - může ukazovat na nevhodné hodnoty cost proměnných, nebo selhání plánovače, např. v důsledku neodhadnutí efektu cache
- největším reálným časem
  - plán může být naprosto v pořádku - za daných podmínek optimální
  - např. vám tam můžech chybět index nebo ho nejde použít kvůli formulaci podmínky, apod.

Neaktuální statistiky

- pokud plánovač nemá statistiky (pg_stats), používá “default” odhady (např. 33%)
- stává se také že statistiky jsou neaktuální – např. po aktualizaci velké části dat
- opraví se buď ručním ANALYZE nebo vyřeší autovacuum

```
CREATE TABLE stale_t (id int);
INSERT INTO stale_t SELECT i FROM generate_series(1,100000) s(i);
-- ANALYZE;
EXPLAIN ANALYZE SELECT id FROM stale_t WHERE id < 100;

                            QUERY PLAN
-------------------------------------------------------------------
 Seq Scan on stale_t  (cost=0.00..1772.00 rows=35440 width=4)
                      (actual time=0.014..9.566 rows=99 loops=1)
   Filter: (id < 100)
   Rows Removed by Filter: 99901
```

Neodhadnutelné podmínky

```
CREATE TABLE a AS SELECT i FROM generate_series(1,10000) s(i);
ANALYZE a;
EXPLAIN SELECT * FROM a WHERE i*i < -1;

                            QUERY PLAN
-------------------------------------------------------------------
Seq Scan on a  (cost=0.00..207.00 rows=3600 width=4)
               (actual time=1.180..1.180 rows=0 loops=1)
   Filter: ((i * i) < (-1))
   Rows Removed by Filter: 10000
 Total runtime: 1.193 ms
```

- plánovač není schopen odhadovat komplexní výrazy (použije default)
- někdy jde přepsat na odhadnutelnou podmínku
  - odstrašující příklad: **“datum::text LIKE '2012-08-%'”**
  - přepis např. **“datum BETWEEN '2012-08-01' AND '2012-09-01'”**
- někdy lze manuálně provést “inverzi”
  - např: **“i*i <= 100” => “i BETWEEN -10 AND 10”**

Korelované sloupce

```
CREATE TABLE a (i int, j int);
INSERT INTO a SELECT i, i FROM generate_series(1,1000000) s(i);
ANALYZE a;
EXPLAIN ANALYZE SELECT * FROM a WHERE (a.i < 1000 AND a.j < 1000);

                          QUERY PLAN
-----------------------------------------------------------
 Seq Scan on a  (cost=0.00..19425.00 rows=1 width=8)
          (actual time=0.008..71.538 rows=999 loops=1)
   Filter: ((i < 1000) AND (j < 1000))
   Rows Removed by Filter: 999001
 Total runtime: 71.579 ms
(4 rows)
```

- odhazy kobinace podmínek založeny na předpokladu nezávislosti
  - selektivita kombinace je součin jednotlivých selektivit
- každá podmínka má selektivitu ~1/1000 = 0.001
  - 0.001 x 0.001 = 0.000001 – jeden řádek, ale i=j (závislost)

Špatný odhad n_distinct

- odhad počtu různých hodnot překvapivě patří k nejtěžším problémům
- většinou sedí, ale pro nějak “divné” databáze může dojít k chybám
- n_distinct není přímo vidět, projevuje se přes “rows” (např. v agregaci)

```
EXPLAIN ANALYZE SELECT i, sum(val) FROM a GROUP BY i;

                                 QUERY PLAN
-------------------------------------------------------------------------------
 HashAggregate  (cost=1788.00..1789.00 rows=100 width=8)
                (actual time=36.341..55.409 rows=100001 loops=1)
   ->  Seq Scan on a  (cost=0.00..1341.00 rows=89400 width=8)
                      (actual time=0.008..6.469 rows=101000 loops=1)
 Total runtime: 58.254 ms
(3 rows)
```

- v extrémních případech může vést až k “out of memory” chybám
- statistiku lze ručně opravit pomocí “**`ALTER TABLE … SET n_distinct …`**”

Prepared statements

- chceme ušetřit na plánování (včetně odhadu kardinalit apod.)
- vede na generický plán
  - nemůže používat konkrétní hodnoty parametrů
  - plánuje se podle nejčastějších hodnot
  - pro netypické hodnoty může dávat neoptimální plány
- od 9.2 se chová trochu jinak (kontroluje hodnoty a případně přeplánuje)

```
CREATE TABLE a (val INT);
INSERT INTO a SELECT 1 FROM gs(1,100000) s(i);
INSERT INTO a SELECT 2;
CREATE INDEX a_idx ON a(val);

PREPARE select_a(int) AS SELECT * FROM a WHERE val = $1;
EXPLAIN EXECUTE select_a(2);

                        QUERY PLAN
-----------------------------------------------------
 Seq Scan on a  (cost=0.00..1693.01 rows=100001 width=4)
   Filter: (val = $1)
(2 rows)
```

Obtížné joiny

- joiny jsou jedny z nejdražších a nejhůře odhadnutelných operací
- tabulka obsahující jen sudé hodnoty

```
CREATE TABLE a AS SELECT 2*i AS i FROM gs(1,100000) s(i);

EXPLAIN SELECT * FROM a a1 JOIN a a2 ON (a1.i = a2.i);

                                QUERY PLAN
-----------------------------------------------------------------------
 Hash Join  (cost=2693.00..6136.00 rows=100000 width=8)
   Hash Cond: (a1.i = a2.i)
   ->  Seq Scan on a a1  (cost=0.00..1443.00 rows=100000 width=4)
   ->  Hash  (cost=1443.00..1443.00 rows=100000 width=4)
         ->  Seq Scan on a a2  (cost=0.00..1443.00 rows=100000 width=4)
```

Obtížné joiny

- joiny jsou jedny z nejdražších a nejhůře odhadnutelných operací
- změňme trochu podmínku (sudý = lichý)

```
CREATE TABLE a AS SELECT 2*i AS i FROM gs(1,100000) s(i);

EXPLAIN SELECT * FROM a a1 JOIN a a2 ON (a1.i = (a2.i - 1));

                                QUERY PLAN
-------------------------------------------------------------------------
 Hash Join  (cost=2693.00..6886.00 rows=100000 width=8)
   Hash Cond: ((a2.i - 1) = a1.i)
   ->  Seq Scan on a a2  (cost=0.00..1443.00 rows=100000 width=4)
   ->  Hash  (cost=1443.00..1443.00 rows=100000 width=4)
         ->  Seq Scan on a a1  (cost=0.00..1443.00 rows=100000 width=4)
```

auto_explain

- často se stává že dotaz / exekuční plán blbne nepredikovatelně (například je pomalý jen v noci)
- při následném ručním průzkumu se všechno zdá naprosto OK - duchařina
- tento modul vám umožní exekuční plán odchytit právě když blbne
- máte stejné možnosti jako s EXPLAIN / EXPLAIN ANALYZE
- zalogovat můžete vše, jen dotazy přes nějaký limit apod.
- http://www.postgresql.org/docs/9.2/static/auto-explain.html

```
auto_explain.log_min_duration = 250
auto_explain.log_analyze = false
auto_explain.log_timing  = false
auto_explain.log_verbose = false
auto_explain.log_buffers = true
auto_explain.log_format = yaml
auto_explain.log_nested_statements = false
```

enable_*

- způsob jak ovlivnit exekuční plán (např. během ladění)
- nelze "hintovat" jako v jiných databázích (to je feature, ne bug)
- varianty operací ale lze zapnout/vypnout pro celý dotaz
  - ve skutečnosi nevypíná ale pouze výrazně znevýhodňuje

- `enable_bitmapscan`
- `enable_indexscan`
- `enable_seqscan`
- `enable_tidscan`
- `enable_indexonlyscan`
- `enable_hashjoin`
- `enable_mergejoin`
- `enable_nestloop`
- `enable_hashagg`
- `enable_material`
- `enable_sort`

Způsoby přístupu k tabulkám

Způsoby přístupu k tabulkám

- Sequetial Scan
- Index Scan
- Index Only Scan
- Bitmap Index Scan
- Function Scan

- *CTE Scan*
- *TID Scan*
- *Foreign Scan*
- *...*

Sequential Scan

- nejjednodušší možný sken – sekvenčně čte tabulku
- řádky může zpracovat filtrem (WHERE podmínka)

```
CREATE TABLE a AS SELECT i FROM gs(1,100000) s(i);
ANALYZE a;
EXPLAIN ANALYZE SELECT i FROM a WHERE i = 1000;

                        QUERY PLAN
-----------------------------------------------------------
 Seq Scan on a  (cost=0.00..1693.00 rows=1 width=4)
                (actual time=0.080..6.866 rows=1 loops=1)
   Filter: (i = 1000)
 Total runtime: 6.880 ms
(3 rows)
```

- efektivní pro malé tabulky nebo při čtení “velké” části dat
- “nešpiní” shared buffers (ring buffer), synchronizované čtení

Index Scan

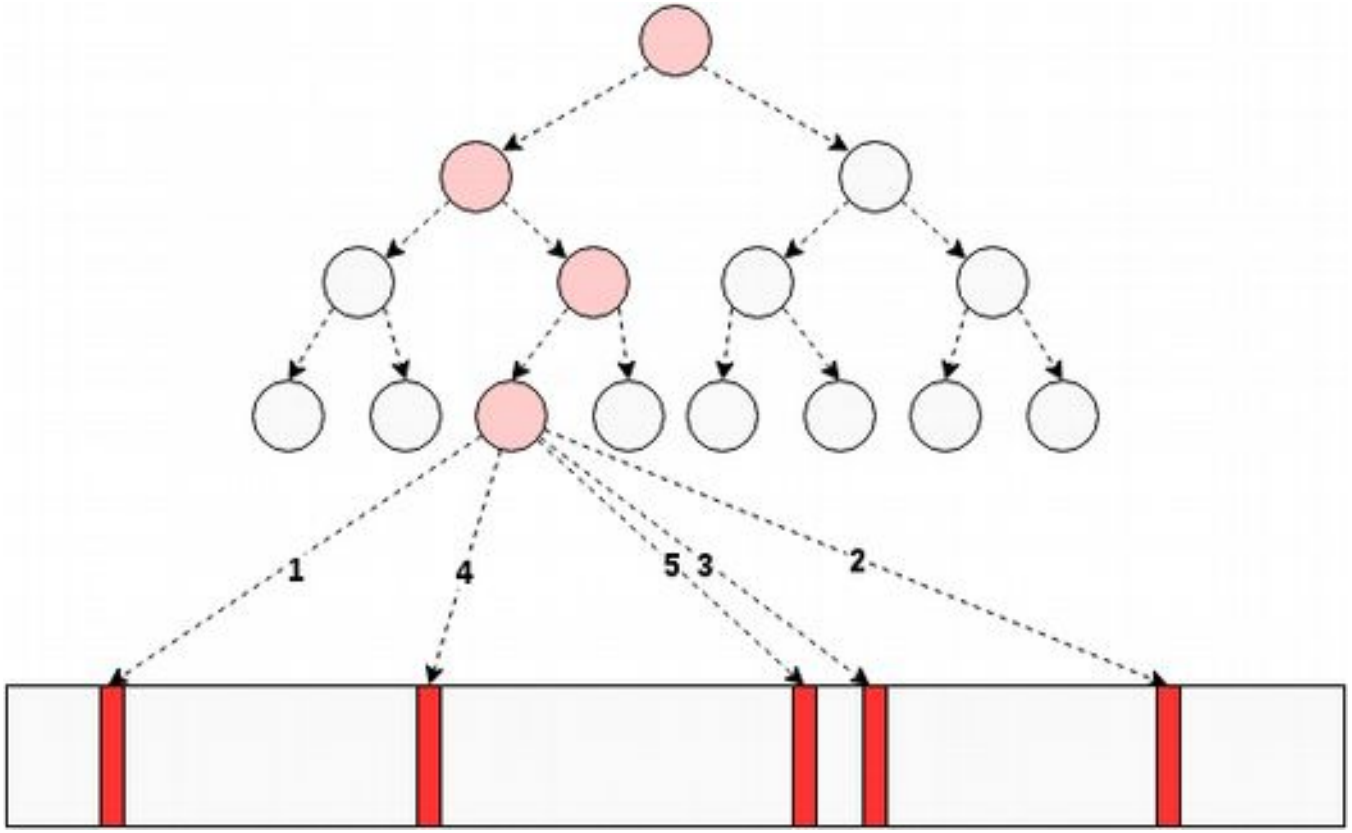

Index Scan

- datová struktura optimalizovaná pro hledání (typicky strom, ale ne nutně)
  - efektivní pro čtení malé části z velké tabulky
  - ne každá podmínka je použitelná pro index

```
CREATE TABLE t4 AS SELECT i AS x, i AS y
                     FROM generate_series(1,100000) s(i);
CREATE INDEX t4_idx ON t4(x);
ANALYZE t4;
EXPLAIN ANALYZE SELECT * FROM t4 WHERE x = 1000 AND y = 1000;

                            QUERY PLAN
-------------------------------------------------------------------
 Index Scan using a_idx on a  (cost=0.00..8.28 rows=1 width=4)
                      (actual time=0.023..0.023 rows=1 loops=1)
   Index Cond: (x = 1000)
   Filter: (y = 1000)
 Total runtime: 0.039 ms
(3 rows)
```

Index Only Scan

- novinka v PostgreSQL 9.2, vylepšení Index Scanu
- pokud index obsahuje všechny potřebné sloupce, lze číst index
- efektivní pokud je dostupná informace o viditelnosti řádek na stránce

```
CREATE TABLE a (id INT, val INT8);
INSER INTO a SELECT i,i FROM gs(1,1000000) s(i);
CREATE INDEX a_idx on a(id, val);

EXPLAIN SELECT val FROM a WHERE id = 230923;

                            QUERY PLAN
-------------------------------------------------------------------
 Index Only Scan using a_idx on a  (cost=0.00..9.81 rows=1 width=8)
   Index Cond: (id = 230923)
(2 rows)
```

Bitmap Index Scan

- Index Scan je efektivní pouze pro selektivní podmínky (např. <5%)
  - nepoužitelné pro podmínky s velkou selektivitou (např. 20%)
  - náhodné I/O nad tabulkou (Index Scan)
  - overhead při práci s indexem (Index Only Scan)

- Bitmap Index Scan čte tabulku sekvenčně pomocí indexu
  - nejdříve na základě indexu vytvoří bitmapu řádek nebo stránek
  - pokud alespoň jedna řádka odpovídá tak “1” jinak “0”
  - bitmap může být více a může je kombinovat (AND, …)
  - následně tabulku sekvenčně přečte pomocí bitmapy
  - musí dělat “recheck” protože neví které řádky vyhovují

Bitmap Index Scan

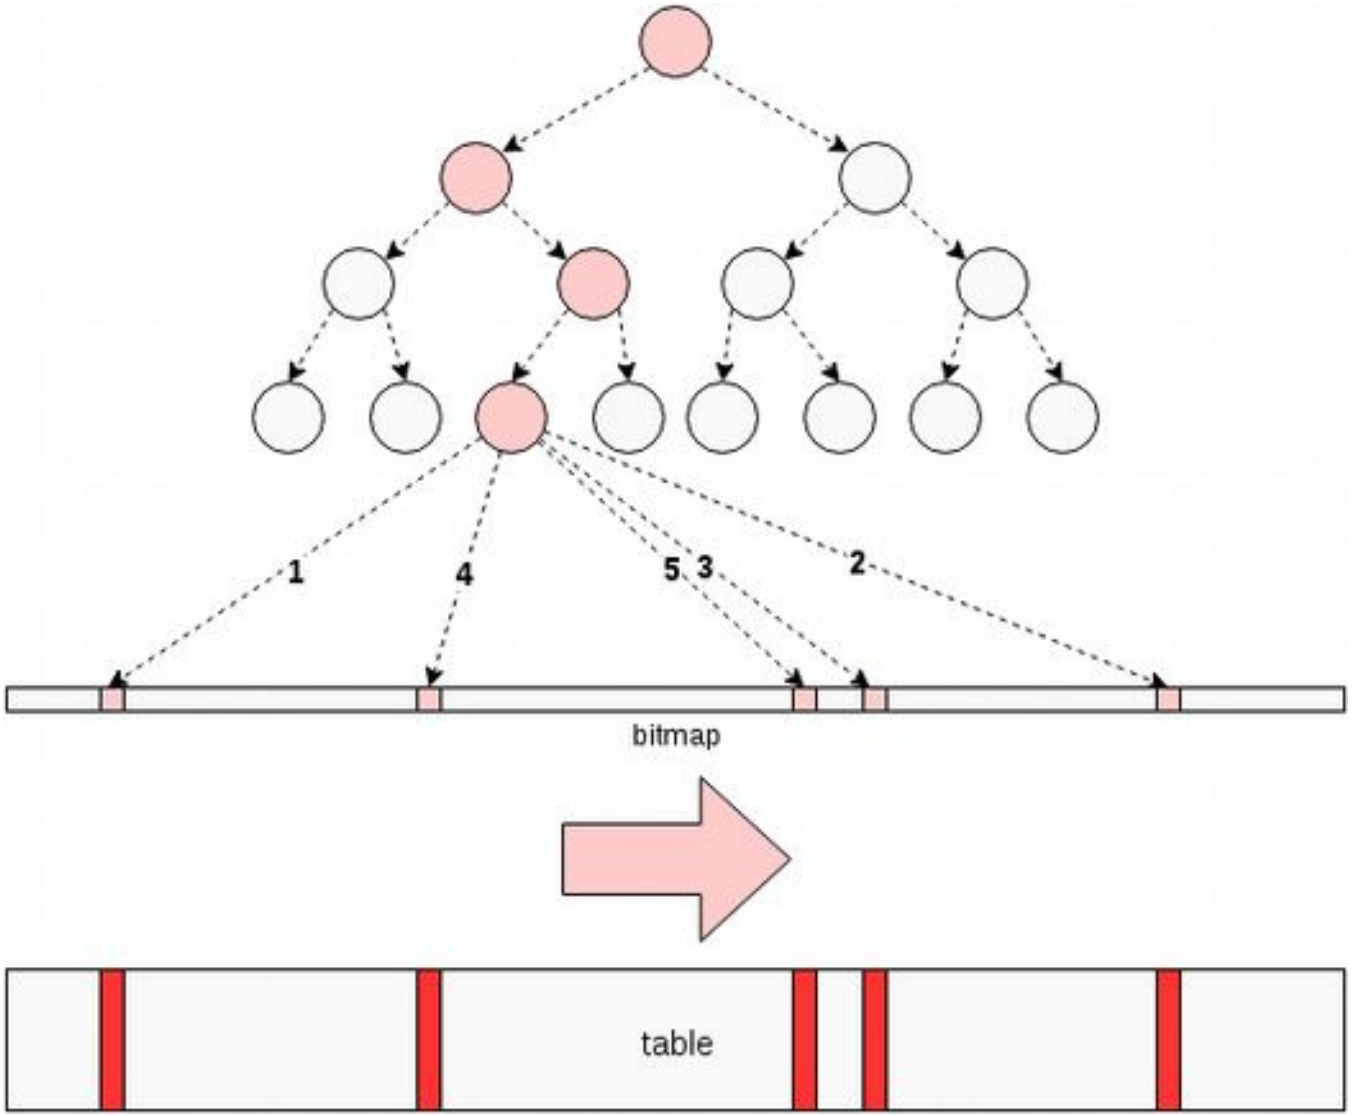

Bitmap Index Scan

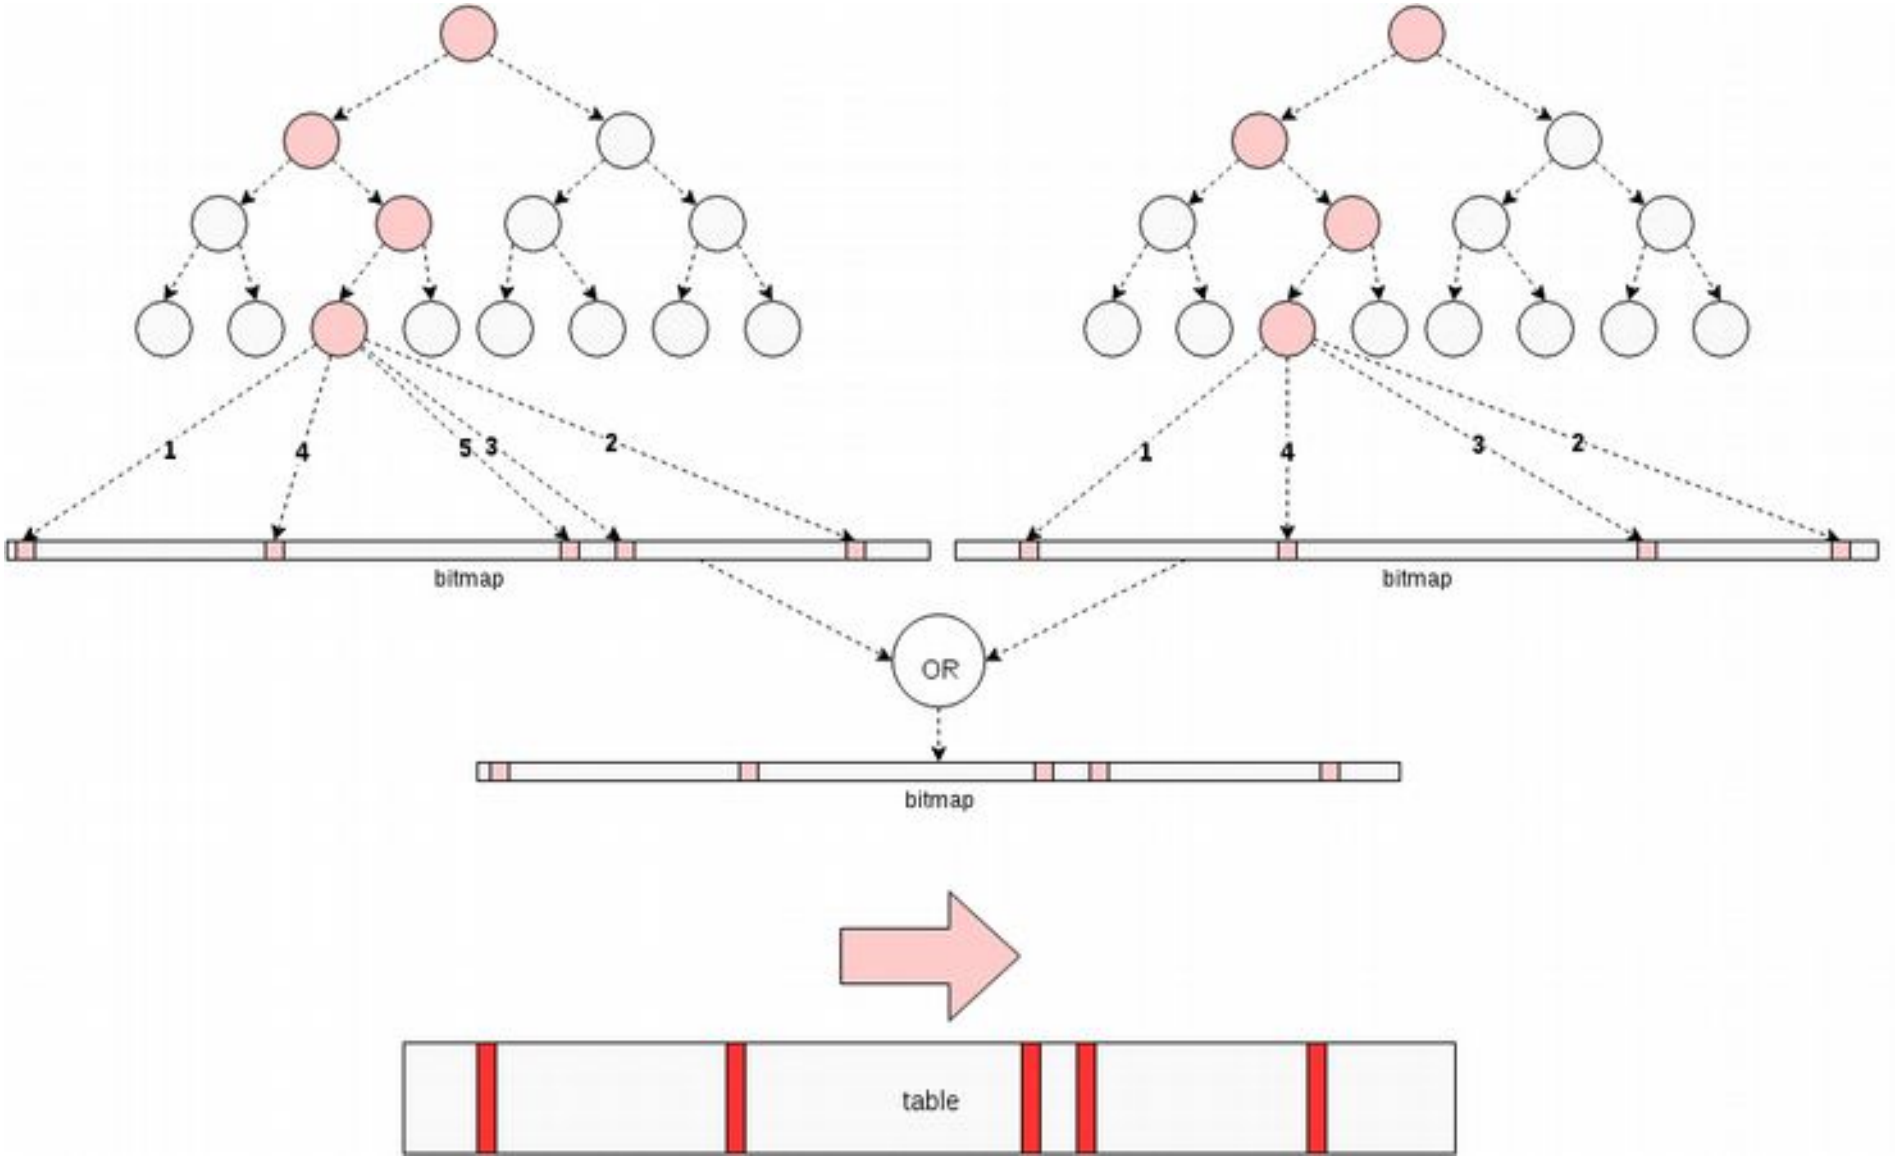

Bitmap Index Scan

```
CREATE TABLE a AS SELECT mod(i,100) AS x,
                         mod(i,101) AS y FROM gs(1,1000000) s(i);

CREATE INDEX ax_idx ON a(x);
CREATE INDEX ay_idx ON a(y);

EXPLAIN SELECT * FROM a WHERE x < 5 AND y < 5;
                                    QUERY PLAN
-------------------------------------------------------------------------
Bitmap Heap Scan on a  (cost=1867.73..5844.45 rows=2537 width=8)
  Recheck Cond: ((x < 5) AND (y < 5))
  ->  BitmapAnd  (cost=1867.73..1867.73 rows=2537 width=0)
        ->  Bitmap Index Scan on ax_idx (cost=0.00..930.10 rows=50233 ...
              Index Cond: (x < 5)
        ->  Bitmap Index Scan on ay_idx (cost=0.00..936.12 rows=50503 ...
              Index Cond: (y < 5)
(7 rows)
```

Srovnání skenů

- vezměme tabulku (1M integerů v náhodném pořadí)
- sledujme cenu 3 základních plánů pro podmínku s různou selektivitou
- nutno vypínat/zapínat jednotlivé varianty
  - enable_seqscan = (on|off)
  - enable_indexscan = (on|off)
  - enable_bitmapscan = (on|off)

```
CREATE TABLE a AS SELECT i, md5(i::text) m
                    FROM generate_series(1,100000) s(i)
                    ORDER BY random();

CREATE INDEX a_idx ON a(i);

SELECT * FROM a WHERE i < (1000000 * selektivita);
```

Srovnání skenů

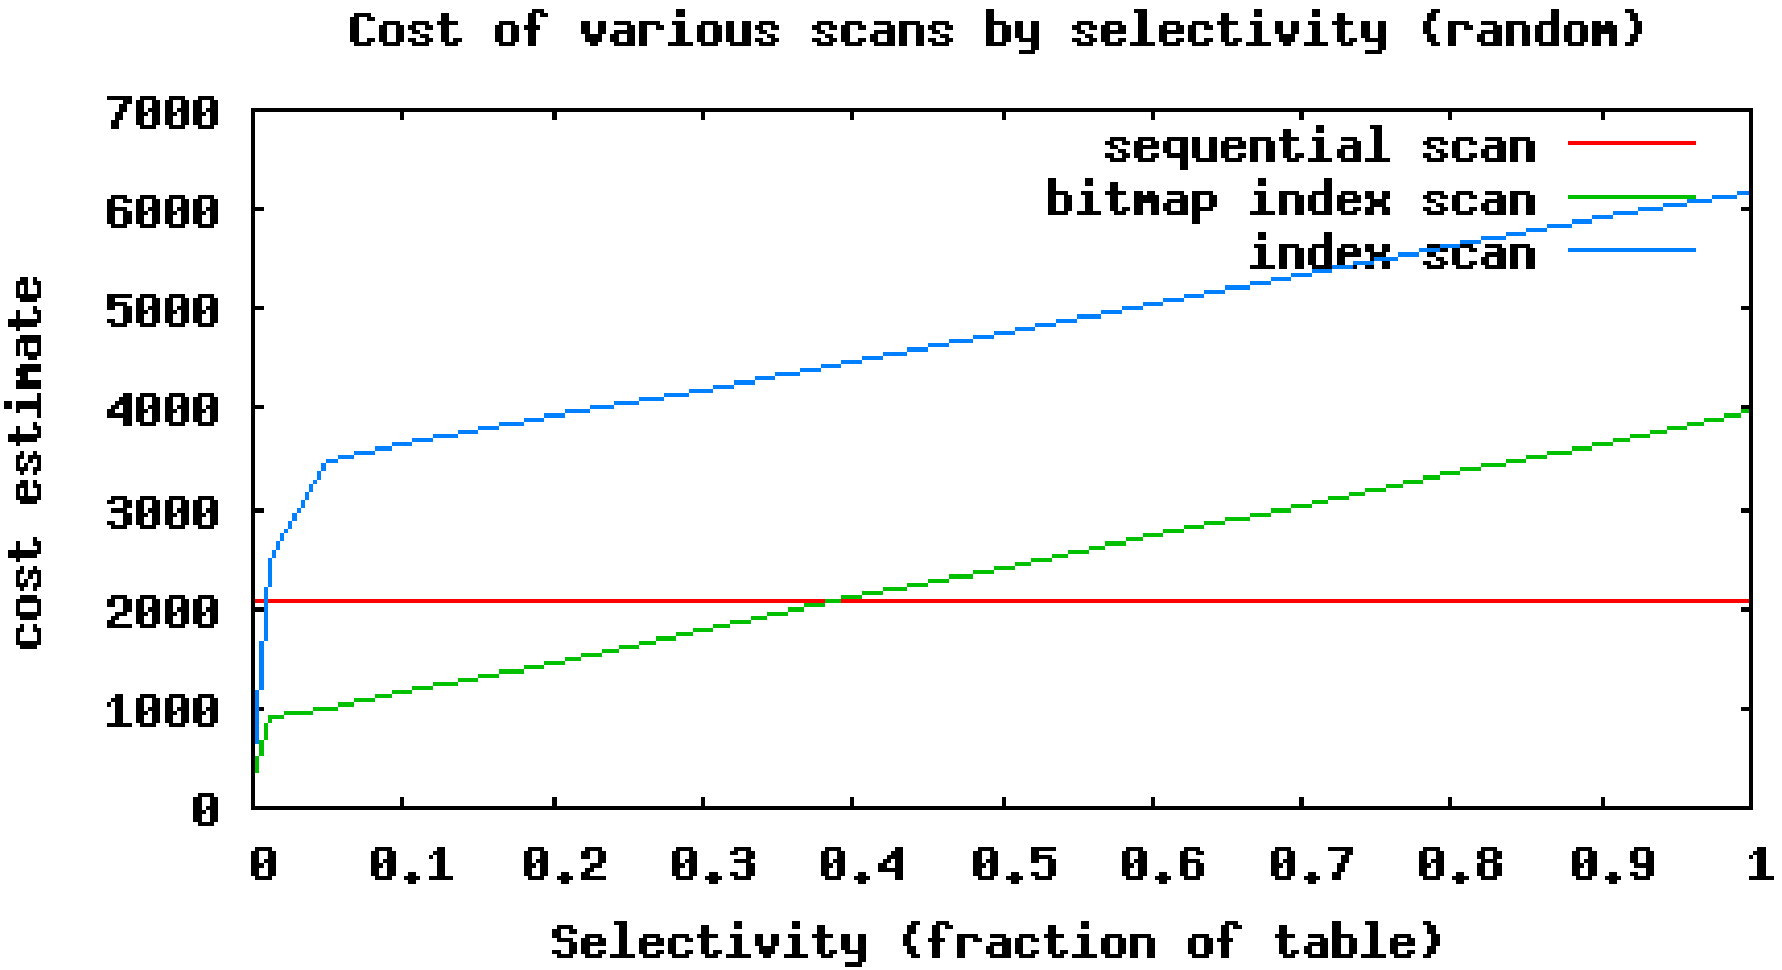

Function Scan

- set-returning-functions (SRF) – funkce vracející tabulku
- ceny a počty řádek jsou konstanty, dané při kompilaci
- nepřesné odhady působí problémy při plánování
- zkuste “generate_series” s různými počty a podmínkami

```
CREATE FUNCTION moje_tabulka(n INT) RETURNS SETOF INT AS $$
DECLARE
    i INT := 0;
BEGIN

    FOR i IN 1..n LOOP
        RETURN NEXT i;
    END LOOP;

    RETURN;

END;
$$ LANGUAGE plpgsql COST 10 ROWS 100;
```

CTE Scan

```
WITH b AS (SELECT * FROM a WHERE i >= 100)
SELECT * FROM b WHERE i <= 110
  UNION ALL
SELECT * FROM b WHERE i <= 120;
```

- opakované výrazy je možno uvést jako “WITH”
- vyhodnotí se jen jednou, ne pro každou větev samostatně

```
                                QUERY PLAN
-----------------------------------------------------------------------
 Result  (cost=17906.00..69567.50 rows=666600 width=12)
   CTE b
     ->  Seq Scan on a  (cost=0.00..17906.00 rows=999900 width=12)
           Filter: (i >= 100)
   ->  Append  (cost=0.00..51661.50 rows=666600 width=12)
         ->  CTE Scan on b  (cost=0.00..22497.75 rows=333300 width=12)
               Filter: (i <= 110)
         ->  CTE Scan on b  (cost=0.00..22497.75 rows=333300 width=12)
               Filter: (i <= 120)
```

- nevyhodnocují se “na začátku” ale průběžně

Další operace

Agregace, třídění, LIMIT, ...

Agregace

- PostgreSQL má tři implementace agregace
  - vybírá se během plánování (nelze měnit za běhu)
- **Aggregate**
  - v případech bez GROUP BY (takže vlastně jediná skupina)
- **Group Aggregate**
  - k detekci skupin využívá třídění vstupní relace
  - nemusí čekat na dokončení agregace, ale potřebuje setříděný vstup
- **Hash Aggregate**
  - využívá hash tabulku, neumožňuje “batching”
  - může alokovat hodně paměti (podhodnocený n_distinct)

Agregace

```
CREATE TABLE a (i INT, j INT, k INT);
INSERT INTO a SELECT mod(i, 1000), mod(i, 1333), mod(i,3498)
                FROM gs(1,100000) s(i);

EXPLAIN SELECT i, count(*) FROM a GROUP BY i;

EXPLAIN SELECT DISTINCT i  FROM a GROUP BY i;

                           QUERY PLAN
-----------------------------------------------------------------
 HashAggregate  (cost=2041.00..2141.00 rows=10000 width=8)
   ->  Seq Scan on a  (cost=0.00..1541.00 rows=100000 width=8)
(2 rows)
```

Agregace / OOM

- HashAggregate není adaptivní
  - plán nelze za běhu změnit (např. na Group Aggregate)
  - hash tabulka nepodporuje batching (na rozdíl od Hash Joinu)
- nestává se často, ale pokud OOM tak většinou z tohoto důvodu
- typicky je důsledkem nepřesných statistik na tabulce

```
EXPLAIN ANALYZE
SELECT i, count(*) FROM generate_series(1,100000000) s(i)
GROUP BY i;

SELECT i, count(i) FROM a GROUP BY i;
ERROR:  out of memory
DETAIL:  Failed on request of size 20.
```

Třídění

- tři základní varianty třídění
  - pomocí indexu (Index Scan / Index Only Scan)
  - v paměti (quick-sort)
  - na disku (merge sort)
- mezi quick-sort a merge-sortem se volí za běhu
  - dokud stačí RAM (work_mem), používá se quick-sort
  - poté se začne zapisovat na disk – nikdy OOM
- třídění pomocí indexu má malé počáteční náklady
  - nemusí čekat na všechny řádky, vrací je hned
  - cena ale rychle roste (podle korelace s tabulkou apod.)
  - v případě Index Only Scan roste cena pomaleji

Třídění

```
EXPLAIN ANALYZE SELECT * FROM a ORDER BY i;

                                QUERY PLAN
-----------------------------------------------------------------------------
 Sort  (cost=114082.84..116582.84 rows=1000000 width=4)
                    (actual time=1018.108..1230.263 rows=1000000 loops=1)
   Sort Key: i
   Sort Method: external merge  Disk: 13688kB
   ->  Seq Scan on a  (cost=0.00..14425.00 rows=1000000 width=4)
                       (actual time=0.005..68.491 rows=1000000 loops=1)
 Total runtime: 1263.166 ms
(5 rows)

CREATE INDEX a_idx ON a(i);
ANALYZE a;

EXPLAIN SELECT * FROM a ORDER BY i;

                                QUERY PLAN
-----------------------------------------------------------------------------
 Index Scan using a_idx on a (cost=0.00..43680.14 rows=1000000 width=4)
(1 row)
```

LIMIT/OFFSET

- zatím jsme pracovali s celkovou cenou (total cost)
- často ale není třeba vyhodnotit všechny řádky
  - například stačí jen ověřit existenci (LIMIT 1)
  - časté jsou "top N" dotazy (ORDER BY x LIMIT n)
- cena LIMIT je lineární interpolací – databáze zná
  - startup a total cost “vnořené” operace
  - počty řádek (požadovaný a celkový)

```
startup_cost + (total_cost – startup_cost) * (rows / limit)
```

LIMIT a rovnoměrné rozložení

- řádky vyhovující podmínce rovnoměrně rozloženy v tabulce

```
CREATE TABLE a (id INT);

INSERT INTO a SELECT mod(i,10000)
                FROM generate_series(1,1000000) s(i);

EXPLAIN ANALYZE SELECT * FROM a WHERE id = 9999 LIMIT 1;

                             QUERY PLAN
---------------------------------------------------------------------
 Limit (cost=0.00..172.70 rows=1 width=4)
       (actual time=0.72..0.72 rows=1 loops=1)
   -> Seq Scan on a (cost=0.00..16925.00 rows=98 width=4)
                    (actual time=0.72..0.72 rows=1 loops=1)
         Filter: (id = 9999)
         Rows Removed by Filter: 9998
```

LIMIT a nerovnoměrné rozložení

- identifikace tohoto problému je poměrně těžká
  - všimněte si “rows removed by filter”

```
CREATE TABLE a (id INT);

INSERT INTO a SELECT i/100
                FROM generate_series(1,1000000) s(i);

EXPLAIN ANALYZE SELECT * FROM a WHERE id = 9999 LIMIT 1;

                              QUERY PLAN
-----------------------------------------------------------------------
 Limit (cost=0.00..172.70 rows=1 width=4)
       (actual time=71.00..71.00 rows=1 loops=1)
   -> Seq Scan on a (cost=0.00..16925.00 rows=98 width=4)
                    (actual time=71.00..71.00 rows=1 loops=1)
       Filter: (id = 9999)
       Rows Removed by Filter: 999899
```

Triggery

- dlouho “temná hmota” exekuce – nikde nebylo vidět
  - kromě doby trvání dotazu ;-)
- zahrnuje i triggery které realizují referenční integritu
- častý problém – cizí klíč bez indexu na child tabulce
  - změny nadřízené tabulky trvají dlouho (např. DELETE)
  - vyžadují totiž kontrolu podřízené tabulky

Triggery

```
CREATE TABLE parent (id INT PRIMARY KEY);
CREATE TABLE child (id  INT PRIMARY KEY,
                    pid INT REFERENCES parent(id));

INSERT INTO parent SELECT i FROM generate_series(1,100) s(i);
INSERT INTO child  SELECT i, 1 from generate_series(1,10000) s(i);

EXPLAIN ANALYZE DELETE FROM parent WHERE id > 1;

                              QUERY PLAN
-----------------------------------------------------------------------
 Delete on parent  (cost=0.00..2.25 rows=100 width=6)
                   (actual time=0.081..0.081 rows=0 loops=1)
   ->  Seq Scan on parent  (cost=0.00..2.25 rows=100 width=6)
                           (actual time=0.007..0.019 rows=99 loops=1)
         Filter: (id > 1)
         Rows Removed by Filter: 1
 Trigger for constraint child_pid_fkey: time=75.671 calls=99
 Total runtime: 75.774 ms
(6 rows)
```

Joinování tabulek

Nested Loop, Hash Join, Merge Join

Joiny obecně

- všechny joiny pracují se dvěma vstupními relacemi
- první je označována jako vnější (outer), druhá jako vnitřní (inner)
  - nemá nic společného s inner/outer joinem
  - vychází z rozdílného postavení tabulek v algoritmech
- **join_collapse_limit = 8**
  - ovlivňuje jak moc může plánovač měnit pořadí tabulek během joinu
  - lze zneužít ke “vnucení” pořadí použitím explicitního joinu

    ```
    SET join_collapse_limit = 1
    ```
- **geqo_threshold = 12**
  - určuje kdy se má opustit vyčerpávající hledání pořadí tabulek a přejít na genetický algoritmus
  - rychlejší ale nemusí najít některé kombinace

Nested Loop

- asi nejjednodušší možný algoritmus
  - smyčka přes "outer" tabulku, dohledání záznamu v "inner" tabulce
- vhodný pro málo iterací a/nebo levný vnitřní plán
  - např. maličká nebo dobře oindexovaná tabulka
- jediná varianta joinu pro kartézský součin a nerovnosti

```
CREATE TABLE a AS SELECT i FROM generate_series(1,10000) s(i);
CREATE TABLE b AS SELECT i FROM generate_series(1,10000) s(i);

EXPLAIN SELECT * FROM a, b;
                              QUERY PLAN
-----------------------------------------------------------------------
 Nested Loop  (cost=0.00..1250315.00 rows=100000000 width=8)
   ->  Seq Scan on a  (cost=0.00..145.00 rows=10000 width=4)
   ->  Materialize  (cost=0.00..195.00 rows=10000 width=4)
         ->  Seq Scan on b  (cost=0.00..145.00 rows=10000 width=4)
```

Nested Loop

- kartézský součin není příliš obvyklý
- přidejme index a podmínku na jednu tabulku

```
CREATE INDEX b_idx ON b(i);
EXPLAIN SELECT * FROM a JOIN b USING (i) WHERE a.i < 10;

                                QUERY PLAN
-------------------------------------------------------------------------
 Nested Loop  (cost=0.00..240.63 rows=9 width=4)
   ->  Seq Scan on a  (cost=0.00..170.00 rows=9 width=4)
         Filter: (i < 10)
   ->  Index Scan using b_idx on b (cost=0.00..7.84 rows=1 width=4)
         Index Cond: (i = a.i)
(5 rows)
```

- vypadá rozumněji, podobné plány jsou celkem běžné
- uvnitř většinou index (only) scan, maličká tabulka, ...

Nested Loop

```
EXPLAIN ANALYZE SELECT * FROM a JOIN b USING (i) WHERE a.i < 10;
                                QUERY PLAN
-------------------------------------------------------------------------
 Nested Loop  (cost=0.00..240.63 rows=9 width=12)
              (actual time=0.013..0.735 rows=9 loops=1)
   ->  Seq Scan on a  (cost=0.00..170.00 rows=9 width=8)
                      (actual time=0.009..0.719 rows=9 loops=1)
         Filter: (i < 10)
         Rows Removed by Filter: 9991
   ->  Index Scan using b_idx on ba  (cost=0.00..7.84 rows=1 width=8)
                                (actual time=0.001..0.001 rows=1 loops=9)
         Index Cond: (i = a.i)
 Total runtime: 0.755 ms
```

- ceny uvedené u vnitřního plánu jsou průměry na jedno volání
- loops - počet volání vnitřního plánu (nemusí se nutně pustit vůbec)
- **obvyklý problém č. 1**: podstřelení odhadu počtu řádek první tabulky
- **obvyklý problém č. 2**: podstřelení ceny vnořeného plánu

Hash Join

```
EXPLAIN SELECT * FROM a JOIN b USING (i) WHERE a.i < 1000;

                              QUERY PLAN
-----------------------------------------------------------------------
 Hash Join  (cost=182.50..375.00 rows=1000 width=12)
   Hash Cond: (b.i = a.i)
   ->  Seq Scan on b  (cost=0.00..145.00 rows=10000 width=8)
   ->  Hash  (cost=170.00..170.00 rows=1000 width=8)
         ->  Seq Scan on a  (cost=0.00..170.00 rows=1000 width=8)
               Filter: (i < 1000)
(6 rows)
```

- menší relaci načte do hash tabulky (pro rychlé vyhledání podle join klíče)
  - pokud se nevejde do work_mem, rozdělí ji na tzv. "batche"
- následně čte větší tabulku a v hash tabulce vyhledává záznamy
  - velká tabulka se batchuje “odpovídajícím” způsobem
  - řádky prvního batche se zjoinují rovnou
  - ostatní se zapíší do batchů (temporary soubory, může znamenat I/O)

Hash Join

```
EXPLAIN ANALYZE SELECT * FROM a JOIN b USING (i);

                                  QUERY PLAN
-------------------------------------------------------------------------------
 Hash Join  (cost=30832.00..74478.00 rows=1000000 width=12)
                    (actual time=247.928..759.196 rows=1000000 loops=1)
   Hash Cond: (a.i = b.i)
   ->  Seq Scan on a  (cost=0.00..14425.00 rows=1000000 width=8)
                      (actual time=0.007..66.813 rows=1000000 loops=1)
   ->  Hash  (cost=14425.00..14425.00 rows=1000000 width=8)
                    (actual time=247.384..247.384 rows=1000000 loops=1)
         Buckets: 4096  Batches: 64  Memory Usage: 625kB
         ->  Seq Scan on b  (cost=0.00..14425.00 rows=1000000 width=8)
                      (actual time=0.004..98.268 rows=1000000 loops=1)
```

- čím víc segmentů, tím hůře
  - může znamenat zapsání / opakovaného čtení velké části tabulky
  - jediné řešení asi je zvětšit work_mem (nebo vymyslet jinou query)
- jedna hash tabulka nepřekročí work_mem (dynamické batchování)
  - ale v plánu může být více hash joinů (násobek work_mem) :-(

Hash Join

```
EXPLAIN ANALYZE SELECT * FROM a JOIN b USING (i);

                                QUERY PLAN
-----------------------------------------------------------------------
 Hash Join  (cost=30832.00..74478.00 rows=1000000 width=12)
                    (actual time=247.928..759.196 rows=1000000 loops=1)
   Hash Cond: (a.i = b.i)
   ->  Seq Scan on a  (cost=0.00..14425.00 rows=1000000 width=8)
                      (actual time=0.007..66.813 rows=1000000 loops=1)
   ->  Hash  (cost=14425.00..14425.00 rows=1000000 width=8)
                    (actual time=247.384..247.384 rows=1000000 loops=1)
         Buckets: 4096  Batches: 64  Memory Usage: 625kB
         ->  Seq Scan on b  (cost=0.00..14425.00 rows=1000000 width=8)
                      (actual time=0.004..98.268 rows=1000000 loops=1)
```

- počet “bucketů” hash tabulky je také důležitý
  - podhodnocení => velký počet hodnot na jeden bucket
  - dlouhý seznam => pomalé vyhledávání v tabulce :-(
- vylepšeno v 9.5 – dynamický počet bucketů, load faktor 1.0

Merge Join

```
CREATE TABLE a AS SELECT i, md5(i::text) val FROM gs(1,100000) s(i);
CREATE TABLE b AS SELECT i, md5(i::text) val FROM gs(1,100000) s(i);
CREATE INDEX a_idx ON a(i);
CREATE INDEX b_idx ON b(i);
ANALYZE;

EXPLAIN SELECT * FROM a JOIN b USING (i);

                                  QUERY PLAN
------------------------------------------------------------------------------
Merge Join  (cost=1.55..83633.87 rows=1000000 width=70)
  Merge Cond: (a.i = b.i)
  ->  Index Scan using a_idx on a  (cost=0.00..34317.36 rows=1000000 ..
  ->  Index Scan using b_idx on b  (cost=0.00..34317.36 rows=1000000 ..
(4 rows)
```

- může být lepší než hash join pokud je setříděné nebo potřebuji setříděné
- v případě třídění pomocí indexu závisí na korelaci index-tabulka
- na rozdíl od hash joinu může mít velmi malou startovací cenu (vnořený index), což je výhodné pokud je třeba jenom pár prvních řádek (LIMIT)

Merge Join

```
DROP INDEX b_idx;
EXPLAIN SELECT * FROM a JOIN b USING (i) ORDER BY i;

                                  QUERY PLAN
-------------------------------------------------------------------------------
 Merge Join  (cost=10397.93..15627.93 rows=102582 width=69)
   Merge Cond: (a.i = b.i)
   ->  Index Scan using a_idx on a (cost=0.00..3441.26 rows=100000 ...
   ->  Sort  (cost=10397.93..10654.39 rows=102582 width=36)
         Sort Key: b.i
         ->  Seq Scan on b  (cost=0.00..1859.82 rows=102582 width=36)
(6 rows)
```

- při plánování dotazu může hrát roli i "nadřazený" uzel
  - v tomto případě "ORDER BY"
- zkuste odstranit ORDER BY část
  - exekuční plán by se měl změnit na jiný typ joinu

Merge Join

- můžeme setkat s tzv. re-scany, pokud joinujeme přes neunikátní sloupce
- typicky 1:M nebo M:N joiny přes cizí klíč(e)
- pokud je toto potřeba, objeví se "Materialize" uzel (tuplestore)

```
CREATE TABLE a AS SELECT i, i/10 j FROM gs(1,1000000) s(i);
CREATE TABLE b AS SELECT i/10 i FROM gs(1,1000000) s(i);

CREATE INDEX a_idx ON a(j);
CREATE INDEX b_idx ON b(i);

EXPLAIN SELECT * FROM a JOIN b ON (a.j = b.i);
                                QUERY PLAN
-------------------------------------------------------------------------
 Merge Join  (cost=0.92..213436.27 rows=10008798 width=12)
   Merge Cond: (a.j = b.i)
   ->  Index Scan using a_j on a  (cost=0.00..30408.36 rows=1000000 ...
   ->  Materialize  (cost=0.00..32908.36 rows=1000000 width=4)
         ->  Index Scan using b_idx on b  (cost=0.00..30408.36 rows=...
(5 rows)
```

- efektivní způsob jak uchovat řádky (tuples), omezeno work_mem

Poddotazy

Korelované a nekorelované, semi/anti-joiny

Korelovaný subselect

```
CREATE TABLE a (id INT PRIMARY KEY);
CREATE TABLE b (id INT PRIMARY KEY, a_id INT REFERENCES a (id),
                val INT, UNIQUE (a_id));

INSERT INTO a SELECT i               FROM gs(1,10000) s(i);
INSERT INTO b SELECT i, i, mod(i,23) FROM gs(1,10000) s(i);

EXPLAIN ANALYZE
  SELECT a.id, (SELECT val FROM b WHERE a_id = a.id) AS val FROM a;

                          QUERY PLAN
-----------------------------------------------------------------
Seq Scan on a (cost=0.00..82941.20 rows=10000 width=4)
              (actual time=0.023..14.477 rows=10000 loops=1)
 SubPlan 1
   -> Index Scan using b_a_id_key on b (cost=0.00..8.28 rows=1 width=4)
                           (actual time=0.001..0.001 rows=1 loops=10000)
         Index Cond: (a_id = a.id)
 Total runtime: 14.920 ms
(5 rows)
```

- SubPlan kroky jsou prováděny opakovaně (pro každý řádek skenu)

Korelovaný subselect

- často lze efektivně přepsat na join

```
EXPLAIN SELECT a.id, b.val FROM a LEFT JOIN b ON (a.id = b.a_id);
                            QUERY PLAN
------------------------------------------------------------------
 Hash Right Join  (cost=270.00..675.00 rows=10000 width=8)
   Hash Cond: (b.a_id = a.id)
   ->  Seq Scan on b  (cost=0.00..155.00 rows=10000 width=8)
   ->  Hash  (cost=145.00..145.00 rows=10000 width=4)
         ->  Seq Scan on a  (cost=0.00..145.00 rows=10000 width=4)
(5 rows)
```

- výrazně nižší cena oproti ceně vnořeného index scanu (82941.20)
- není úplně ekvivalentní, takže to DB nemůže dělat automaticky
  - jinak se chová k duplicitám v "b" (join nespadne)
- přepis jde použít i na agregační subselecty, např.

```
SELECT a.id, (SELECT SUM(val) FROM b WHERE a_id = a.id) FROM a;

SELECT a.id, SUM(b.val) FROM a LEFT JOIN b ON (a.id = b.a_i)
                                            GROUP BY a.id;
```

Nekorelovaný subselect

```
EXPLAIN SELECT a.id, (SELECT val FROM b LIMIT 1) AS val FROM a;

                              QUERY PLAN
-----------------------------------------------------------------------
 Seq Scan on a  (cost=0.02..145.02 rows=10000 width=4)
   InitPlan 1 (returns $0)
     ->  Limit  (cost=0.00..0.02 rows=1 width=4)
           ->  Seq Scan on b  (cost=0.00..155.00 rows=10000 width=4)
(4 rows)
```

- vyhodnoceno jen jednou na začátku
- přepis na join většinou méně efektivní (náklady na join převažují)

```
EXPLAIN SELECT a.id, x.val FROM a, (SELECT val FROM b LIMIT 1) x;
                             QUERY PLAN
--------------------------------------------------------------------
 Nested Loop  (cost=0.00..245.03 rows=10000 width=8)
   ->  Limit  (cost=0.00..0.02 rows=1 width=4)
         ->  Seq Scan on b  (cost=0.00..155.00 rows=10000 width=4)
   ->  Seq Scan on a  (cost=0.00..145.00 rows=10000 width=4)
(4 rows)
```

EXISTS

```
CREATE TABLE a (id INT PRIMARY KEY);
CREATE TABLE b (id INT PRIMARY KEY);

INSERT INTO a SELECT i FROM gs(1,10000) s(i);
INSERT INTO b SELECT i FROM gs(1,10000) s(i);

SELECT * FROM a WHERE EXISTS (SELECT 1 FROM b WHERE id = a.id);
                              QUERY PLAN
-----------------------------------------------------------------------
 Hash Semi Join  (cost=270.00..665.00 rows=10000 width=4)
   Hash Cond: (a.id = b.id)
   ->  Seq Scan on a  (cost=0.00..145.00 rows=10000 width=4)
   ->  Hash  (cost=145.00..145.00 rows=10000 width=4)
         ->  Seq Scan on b  (cost=0.00..145.00 rows=10000 width=4)

SELECT * FROM a WHERE id IN (SELECT id FROM b);
                              QUERY PLAN
-----------------------------------------------------------------------
 Hash Semi Join  (cost=270.00..665.00 rows=10000 width=4)
   Hash Cond: (a.id = b.id)
   ->  Seq Scan on a  (cost=0.00..145.00 rows=10000 width=4)
   ->  Hash  (cost=145.00..145.00 rows=10000 width=4)
         ->  Seq Scan on b  (cost=0.00..145.00 rows=10000 width=4)
```

NOT EXISTS

```
SELECT * FROM a WHERE NOT EXISTS (SELECT id FROM b WHERE id = a.id);
                              QUERY PLAN
-----------------------------------------------------------------------
 Hash Anti Join  (cost=270.00..565.00 rows=1 width=4)
   Hash Cond: (a.id = b.id)
   ->  Seq Scan on a  (cost=0.00..145.00 rows=10000 width=4)
   ->  Hash  (cost=145.00..145.00 rows=10000 width=4)
         ->  Seq Scan on b  (cost=0.00..145.00 rows=10000 width=4)

SELECT * FROM a WHERE id NOT IN (SELECT id FROM b);
                             QUERY PLAN
---------------------------------------------------------------------
 Seq Scan on a  (cost=170.00..340.00 rows=5000 width=4)
   Filter: (NOT (hashed SubPlan 1))
   SubPlan 1
     ->  Seq Scan on b  (cost=0.00..145.00 rows=10000 width=4)
```

Hádanka: Proč se tyto plány liší když pro EXISTS a IN jsou stejné?

Ukázky dotazů

```
CREATE TABLE foo AS SELECT generate_series(1,1000000) i;
CREATE INDEX ON foo(i);
ANALYZE foo;

EXPLAIN ANALYZE
  SELECT i FROM foo
UNION ALL
  SELECT i FROM foo
ORDER BY 1 LIMIT 100;

 Limit  (cost=0.01..3.31 rows=100 width=4)
        (actual time=0.028..0.078 rows=100 loops=1)
   ->  Result  (cost=0.01..65981.61 rows=2000000 width=4)
               (actual time=0.026..0.064 rows=100 loops=1)
         ->  Merge Append  (cost=0.01..65981.61 rows=2000000 width=4)
                           (actual time=0.026..0.053 rows=100 loops=1)
               Sort Key: public.foo.i
               ->  Index Only Scan using foo_i_idx on foo
                                 (cost=0.00..20490.80 rows=1000000 width=4)
                                 (actual time=0.017..0.021 rows=51 loops=1)
                     Heap Fetches: 0
               ->  Index Only Scan using foo_i_idx on foo
                                 (cost=0.00..20490.80 rows=1000000 width=4)
                                 (actual time=0.007..0.012 rows=50 loops=1)
                     Heap Fetches: 0
 Total runtime: 0.106 ms
```

```
CREATE TABLE foo AS SELECT generate_series(1,1000000) i;
CREATE INDEX ON foo(i);
ANALYZE foo;

EXPLAIN ANALYZE
  SELECT i FROM foo WHERE i IS NOT NULL
UNION ALL
  SELECT i FROM foo WHERE i IS NOT NULL
ORDER BY 1 LIMIT 100;

Limit  (cost=127250.56..127250.81 rows=100 width=4)
       (actual time=1070.799..1070.812 rows=100 loops=1)
   ->  Sort  (cost=127250.56..132250.56 rows=2000000 width=4)
             (actual time=1070.798..1070.804 rows=100 loops=1)
         Sort Key: public.foo.i
         Sort Method: top-N heapsort  Memory: 29kB
         ->  Result  (cost=0.00..50812.00 rows=2000000 width=4)
                          (actual time=0.009..786.806 rows=2000000 loops=1)
               ->  Append  (cost=0.00..50812.00 rows=2000000 width=4)
                          (actual time=0.007..512.201 rows=2000000 loops=1)
                     ->  Seq Scan on foo
                                (cost=0.00..15406.00 rows=1000000 width=4)
                           (actual time=0.007..144.872 rows=1000000 loops=1)
                       Filter: (i IS NOT NULL)
                     ->  Seq Scan on foo
                                (cost=0.00..15406.00 rows=1000000 width=4)
                           (actual time=0.003..139.196 rows=1000000 loops=1)
                       Filter: (i IS NOT NULL)
 Total runtime: 1070.847 ms
```

```
EXPLAIN ANALYZE
SELECT initcap (fullname), initcap(issuer),
       upper(rsymbol), initcap(industry), activity
FROM changes WHERE activity IN (4,5)
                AND mfiled >= (SELECT MAX(mfiled) FROM changes)
ORDER BY shareschange ASC LIMIT 15

                                    QUERY PLAN
-------------------------------------------------------------------------------
 Limit  (cost=0.66..76.91 rows=15 width=98)
        (actual time=5346.850..5366.482 rows=15 loops=1)
   InitPlan 2 (returns $1)
     ->  Result  (cost=0.65..0.66 rows=1 width=0)
                 (actual time=0.076..0.077 rows=1 loops=1)
           InitPlan 1 (returns $0)
             ->  Limit  (cost=0.00..0.65 rows=1 width=4)
                        (actual time=0.063..0.065 rows=1 loops=1)
                   ->  Index Scan Backward using changes_mfiled on changes
                                    (cost=0.00..917481.00 rows=1414912 width=4)
                                    (actual time=0.058..0.058 rows=1 loops=1)
                         Index Cond: (mfiled IS NOT NULL)
   ->  Index Scan using changes_shareschange on changes
                              (cost=0.00..925150.26 rows=181997 width=98)
                              (actual time=5346.846..5366.430 rows=15 loops=1)
         Filter: ((activity = ANY ('{4,5}'::integer[])) AND (mfiled >= $1))
 Total runtime: 5366.578 ms
```

```
EXPLAIN ANALYZE
SELECT initcap (fullname), initcap(issuer),
       upper(rsymbol), initcap(industry), activity
FROM changes WHERE activity IN (4,5)
                AND mfiled >= (SELECT MAX(mfiled) FROM changes)
ORDER BY shareschange DESC LIMIT 15

                                    QUERY PLAN
-------------------------------------------------------------------------------
 Limit  (cost=0.66..76.91 rows=15 width=98)
        (actual time=3.167..15.895 rows=15 loops=1)
   InitPlan 2 (returns $1)
     ->  Result  (cost=0.65..0.66 rows=1 width=0)
                 (actual time=0.042..0.044 rows=1 loops=1)
           InitPlan 1 (returns $0)
             ->  Limit  (cost=0.00..0.65 rows=1 width=4)
                        (actual time=0.033..0.035 rows=1 loops=1)
                   ->  Index Scan Backward using changes_mfiled on changes
                                    (cost=0.00..917481.00 rows=1414912 width=4)
                                    (actual time=0.029..0.029 rows=1 loops=1)
                         Index Cond: (mfiled IS NOT NULL)
   ->  Index Scan Backward using changes_shareschange on changes
                                    (cost=0.00..925150.26 rows=181997 width=98)
                                    (actual time=3.161..15.843 rows=15 loops=1)
         Filter: ((activity = ANY ('{4,5}'::integer[])) AND (mfiled >= $1))
 Total runtime: 15.998 ms
```

```
SELECT email.stuff FROM email NATURAL JOIN link_url NATURAL JOIN email_link
                    WHERE machine = 'foo.bar.com';

                                                                                QUERY PLAN
-------------------------------------------------------------------------------------------------------------------------------------------
Merge Join  (cost=3949462.38..8811048.82 rows=4122698 width=7)
             (actual time=771578.076..777749.755 rows=3 loops=1)
   Merge Cond: (email.message_id = link_url.message_id)
   ->  Index Scan using email_pkey on email  (cost=0.00..4561330.19 rows=79154951 width=11)
                                    (actual time=0.041..540883.445 rows=79078427 loops=1)
   ->  Materialize  (cost=3948986.49..4000520.21 rows=4122698 width=4)
             (actual time=227023.820..227023.823 rows=3 loops=1)
         ->  Sort  (cost=3948986.49..3959293.23 rows=4122698 width=4)
                   (actual time=227023.816..227023.819 rows=3 loops=1)
               Sort Key: link_url.message_id
               Sort Method:  quicksort  Memory: 25kB
               ->  Hash Join  (cost=9681.33..3326899.30 rows=4122698 width=4)
                              (actual time=216443.617..227023.798 rows=3 loops=1)
                     Hash Cond: (link_url.urlid = email_link.urlid)
                     ->  Seq Scan on link_url  (cost=0.00..2574335.33 rows=140331133 width=37)
                                               (actual time=0.013..207980.261 rows=140330592 loops=1)
                     ->  Hash  (cost=9650.62..9650.62 rows=2457 width=33)
                                (actual time=0.074..0.074 rows=1 loops=1)
                           ->  Bitmap Heap Scan on email_link
                                                    (cost=97.10..9650.62 rows=2457 width=33)
                                                 (actual time=0.072..0.072 rows=1 loops=1)
                                 Recheck Cond: (hostname = 'foo.bar.com'::text)
                                 ->  Bitmap Index Scan on hostdex
                                                          (cost=0.00..96.49 rows=2457 width=0)
                                                       (actual time=0.060..0.060 rows=1 loops=1)
                                       Index Cond: (hostname = 'foo.bar.com'::text)
 Total runtime: 777749.820 ms
(16 rows)
```

```
SELECT email.stuff FROM email NATURAL JOIN link_url NATURAL JOIN email_link
                    WHERE machine = 'foo.bar.com';

                                                                                QUERY PLAN
-------------------------------------------------------------------------------------------------------------------------------------------
Merge Join  (cost=3949462.38..8811048.82 rows=4122698 width=7)
             (actual time=771578.076..777749.755 rows=3 loops=1)
   Merge Cond: (email.message_id = link_url.message_id)
   ->  Index Scan using email_pkey on email  (cost=0.00..4561330.19 rows=79154951 width=11)
                                    (actual time=0.041..540883.445 rows=79078427 loops=1)
   ->  Materialize  (cost=3948986.49..4000520.21 rows=4122698 width=4)
             (actual time=227023.820..227023.823 rows=3 loops=1)
         ->  Sort  (cost=3948986.49..3959293.23 rows=4122698 width=4)
                   (actual time=227023.816..227023.819 rows=3 loops=1)
               Sort Key: link_url.message_id
               Sort Method:  quicksort  Memory: 25kB
               ->  Hash Join  (cost=9681.33..3326899.30 rows=4122698 width=4)
                              (actual time=216443.617..227023.798 rows=3 loops=1)
                     Hash Cond: (link_url.urlid = email_link.urlid)
                     ->  Seq Scan on link_url  (cost=0.00..2574335.33 rows=140331133 width=37)
                                               (actual time=0.013..207980.261 rows=140330592 loops=1)
                     ->  Hash  (cost=9650.62..9650.62 rows=2457 width=33)
                                (actual time=0.074..0.074 rows=1 loops=1)
                           ->  Bitmap Heap Scan on email_link
                                                    (cost=97.10..9650.62 rows=2457 width=33)
                                                (actual time=0.072..0.072 rows=1 loops=1)
                                 Recheck Cond: (hostname = 'foo.bar.com'::text)
                                 ->  Bitmap Index Scan on hostdex
                                                          (cost=0.00..96.49 rows=2457 width=0)
                                                      (actual time=0.060..0.060 rows=1 loops=1)
                                       Index Cond: (hostname = 'foo.bar.com'::text)
 Total runtime: 777749.820 ms
(16 rows)
```

```
EXPLAIN ANALYZE SELECT * FROM parent ORDER BY id DESC LIMIT 100;

                                                                  QUERY PLAN
-----------------------------------------------------------------------------------------------------------------------------------------------
Limit  (cost=105288.65..105288.90 rows=100 width=4)
    (actual time=868.998..869.010 rows=100 loops=1)
   ->  Sort  (cost=105288.65..110288.65 rows=2000002 width=4)
          (actual time=868.996..869.002 rows=100 loops=1)
         Sort Key: public.parent.id
         Sort Method: top-N heapsort  Memory: 29kB
         ->  Result  (cost=0.00..28850.01 rows=2000002 width=4)
               (actual time=0.007..442.538 rows=2000001 loops=1)
                ->  Append  (cost=0.00..28850.01 rows=2000002 width=4)
                     (actual time=0.006..259.906 rows=2000001 loops=1)
                      ->  Seq Scan on parent  (cost=0.00..0.00 rows=1 width=4)
                                   (actual time=0.001..0.001 rows=0 loops=1)
                      ->  Seq Scan on child_1 parent
                                  (cost=0.00..14425.00 rows=1000000 width=4)
                              (actual time=0.005..70.153 rows=1000000 loops=1)
                      ->  Seq Scan on child_2 parent
                                  (cost=0.00..14425.01 rows=1000001 width=4)
                              (actual time=0.005..70.757 rows=1000001 loops=1)
 Total runtime: 869.032 ms
(10 rows)
```

```
EXPLAIN ANALYZE SELECT * FROM parent ORDER BY id DESC LIMIT 100;

                                                                  QUERY PLAN
-----------------------------------------------------------------------------------------------------------------------------------------------
Limit  (cost=105288.65..105288.90 rows=100 width=4)
    (actual time=868.998..869.010 rows=100 loops=1)
   ->  Sort  (cost=105288.65..110288.65 rows=2000002 width=4)
          (actual time=868.996..869.002 rows=100 loops=1)
         Sort Key: public.parent.id
         Sort Method: top-N heapsort  Memory: 29kB
         ->  Result  (cost=0.00..28850.01 rows=2000002 width=4)
               (actual time=0.007..442.538 rows=2000001 loops=1)
                ->  Append  (cost=0.00..28850.01 rows=2000002 width=4)
                     (actual time=0.006..259.906 rows=2000001 loops=1)
                      ->  Seq Scan on parent  (cost=0.00..0.00 rows=1 width=4)
                                  (actual time=0.001..0.001 rows=0 loops=1)
                      ->  Seq Scan on child_1 parent
                                  (cost=0.00..14425.00 rows=1000000 width=4)
                             (actual time=0.005..70.153 rows=1000000 loops=1)
                      ->  Seq Scan on child_2 parent
                                  (cost=0.00..14425.01 rows=1000001 width=4)
                             (actual time=0.005..70.757 rows=1000001 loops=1)
 Total runtime: 869.032 ms
(10 rows)
```

```
                                                                  QUERY PLAN
-----------------------------------------------------------------------------------------------------------------------------------------------
GroupAggregate  (cost=5533840.89..11602495531.58 rows=1 width=16)
   CTE subQuery_1
     ->  Hash Join  (cost=40901.65..1382282.90 rows=10153012 width=9)
           Hash Cond: (public.f_order.orderid_id = public.f_ordersummary.id)
           ->  Seq Scan on f_order  (cost=0.00..1108961.30 rows=10550730 width=13)
           ->  Hash  (cost=31005.97..31005.97 rows=791654 width=4)
                 ->  Seq Scan on f_ordersummary  (cost=0.00..31005.97 rows=791654 width=4)
                       Filter: (orderstatus_id <> ALL ('{15,86406,86407,86412}'::integer[]))
   CTE subQuery_0
     ->  Hash Join  (cost=40901.65..1382282.90 rows=10153012 width=8)
           Hash Cond: (public.f_order.orderid_id = public.f_ordersummary.id)
           ->  Seq Scan on f_order  (cost=0.00..1108961.30 rows=10550730 width=12)
           ->  Hash  (cost=31005.97..31005.97 rows=791654 width=4)
                 ->  Seq Scan on f_ordersummary  (cost=0.00..31005.97 rows=791654 width=4)
                       Filter: (orderstatus_id <> ALL ('{15,86406,86407,86412}'::integer[]))
   ->  Merge Full Join  (cost=2769275.09..7734093990.56 rows=515418263361 width=16)
         Merge Cond: ("subQuery_1".pk = "subQuery_0".pk)
         ->  Sort  (cost=1384637.54..1410020.07 rows=10153012 width=12)
               Sort Key: "subQuery_1".pk
               ->  CTE Scan on "subQuery_1"  (cost=0.00..203060.24 rows=10153012 width=12)
         ->  Sort  (cost=1384637.54..1410020.07 rows=10153012 width=12)
               Sort Key: "subQuery_0".pk
               ->  CTE Scan on "subQuery_0"  (cost=0.00..203060.24 rows=10153012 width=12)
```

```
                                                                  QUERY PLAN
-----------------------------------------------------------------------------------------------------------------------------------------------
GroupAggregate  (cost=5533840.89..11602495531.58 rows=1 width=16)
   CTE subQuery_1
     ->  Hash Join  (cost=40901.65..1382282.90 rows=10153012 width=9)
           Hash Cond: (public.f_order.orderid_id = public.f_ordersummary.id)
           ->  Seq Scan on f_order  (cost=0.00..1108961.30 rows=10550730 width=13)
           ->  Hash  (cost=31005.97..31005.97 rows=791654 width=4)
                 ->  Seq Scan on f_ordersummary  (cost=0.00..31005.97 rows=791654 width=4)
                       Filter: (orderstatus_id <> ALL ('{15,86406,86407,86412}'::integer[]))
   CTE subQuery_0
     ->  Hash Join  (cost=40901.65..1382282.90 rows=10153012 width=8)
           Hash Cond: (public.f_order.orderid_id = public.f_ordersummary.id)
           ->  Seq Scan on f_order  (cost=0.00..1108961.30 rows=10550730 width=12)
           ->  Hash  (cost=31005.97..31005.97 rows=791654 width=4)
                 ->  Seq Scan on f_ordersummary  (cost=0.00..31005.97 rows=791654 width=4)
                       Filter: (orderstatus_id <> ALL ('{15,86406,86407,86412}'::integer[]))
   ->  Merge Full Join  (cost=2769275.09..7734093990.56 rows=515418263361 width=16)
         Merge Cond: ("subQuery_1".pk = "subQuery_0".pk)
         ->  Sort  (cost=1384637.54..1410020.07 rows=10153012 width=12)
               Sort Key: "subQuery_1".pk
               ->  CTE Scan on "subQuery_1"  (cost=0.00..203060.24 rows=10153012 width=12)
         ->  Sort  (cost=1384637.54..1410020.07 rows=10153012 width=12)
               Sort Key: "subQuery_0".pk
               ->  CTE Scan on "subQuery_0"  (cost=0.00..203060.24 rows=10153012 width=12)
```

```
CREATE TABLE toasted (id SERIAL, val TEXT);
INSERT INTO toasted SELECT i, REPEAT(MD5(i::text),80)
                      FROM generate_series(1,1000000) s(i);

EXPLAIN ANALYZE SELECT id, LENGTH(val) FROM toasted;

                              QUERY PLAN
-----------------------------------------------------------------------
 Seq Scan on toasted  (cost=0.00..25834.00 rows=1000000 width=36)
                (actual time=0.018..8060.214 rows=1000000 loops=1)
 Total runtime: 8088.929 ms
(2 rows)

EXPLAIN ANALYZE SELECT id, LENGTH(id::text) FROM toasted;

                              QUERY PLAN
-----------------------------------------------------------------------
 Seq Scan on toasted  (cost=0.00..30834.00 rows=1000000 width=4)
                 (actual time=0.011..218.352 rows=1000000 loops=1)
 Total runtime: 246.334 ms
(2 rows)
```